ÜBERARBEITETE FASSUNG · 16.10.2026

Machine Learning in Finanz-, Börsen- und Politikprognosen

Welche Art des Lernens und welches Modell wählen — überarbeitete Fassung deiner beiden Texte: der Einteilung der Kursthemen in überwachtes und unüberwachtes Lernen und der Notiz „ML_Trading“.

TEILE 1–2
Begriffe und Kursthemen: was überwacht ist, was unüberwacht, wo Deep Learning hingehört.

TEILE 3–7
Überarbeiteter Text zu Prognosen, mit zwei neuen Kapiteln (5 und 6), die im Original fehlten.

AM ENDE
Liste der Änderungen gegenüber dem Original und die Quellen, auf denen die Korrekturen beruhen.

1. Zuerst die Begriffe: Art des Lernens ist nicht gleich Art des Modells

Überwachtes Lernen (supervised) — die Daten haben ein Label, also eine Zielvariable, und das Modell lernt, es vorherzusagen. Ist das Label eine Zahl, ist es Regression (z. B. Rendite, Ausgaben); ist es eine Klasse — Klassifikation (z. B. steigt/fällt, klickt/klickt nicht).

Unüberwachtes Lernen (unsupervised) — es gibt kein Label. Der Algorithmus sucht Struktur in den Daten selbst: Gruppen (Clustering), Richtungen der größten Streuung (PCA) oder ungewöhnliche Beobachtungen (Anomalien).

Selbstüberwachtes Lernen (self-supervised) — das Label entsteht aus den Daten selbst, z. B. das nächste Wort im Text. So lernen Word2Vec und Sprachmodelle; meist zählt man sie zu den Methoden ohne manuelle Labels.

Deep Learning ist keine weitere Art des Lernens, sondern eine Modellfamilie — neuronale Netze. Ein Netz kann überwacht lernen (ein LSTM, das eine Rendite vorhersagt), unüberwacht (ein Autoencoder) oder selbstüberwacht (ein Sprachmodell).

Modellfamilie × Art des Lernens — Beispiele

MODELLFAMILIE	ÜBERWACHTES LERNEN — MIT LABEL	OHNE LABEL — UNÜBERWACHT / SELBSTÜBERWACHT
Lineare und statistische Modelle	lineare Regression, logistische Regression, Ridge, Lasso	PCA
Geometrische Verfahren (Abstand, Margin)	KNN, SVM	K-Means, One-Class SVM
Bäume und ihre Ensembles	Entscheidungsbaum, Random Forest, XGBoost, LightGBM	Isolation Forest (Anomalien)
Neuronale Netze (Deep Learning)	MLP, LSTM und Transformer für Prognosen, Sentiment-Klassifikation	Autoencoder; Word2Vec und Sprachmodelle (selbstüberwacht)

DIE WICHTIGSTE KORREKTUR

Im Originaltext stand Deep Learning neben supervised und unsupervised als dritte Möglichkeit. Das ist ein begrifflicher Fehler: Ein LSTM oder Transformer, der einen Preis vorhersagt, lernt überwacht — genau wie XGBoost. Der richtige Vergleich ist **einfache Modelle (linear, Bäume) gegen neuronale Netze**, alle im Rahmen des überwachten Lernens.

2. Kursthemen: überwacht oder unüberwacht?

Die korrigierte Einteilung der Themen aus deiner Liste. Wo ich dein Kurs-Notebook kenne, nenne ich das Label, das es verwendet.

THEMA	ART DES LERNENS	WARUM / WORAUF ACHTEN
1-Linear_Regression	**überwacht** Regression	Das Label ist eine Zahl — im Projekt die jährlichen Ausgaben des Kunden (`Yearly Amount Spent`).
2-Logistic_Regression	**überwacht** Klassifikation	Das Label ist eine Klasse — ein Klick auf eine Anzeige (`Clicked on Ad`).
3-K_Nearest_Neighbors	**überwacht** Klassifikation (meist)	Braucht Labels (`TARGET CLASS`). Nicht mit K-Means verwechseln. Ohne Labels funktioniert nur die reine Suche nach den nächsten Nachbarn (`NearestNeighbors`).
4-Decision_Trees_und_ Random_Forests	**überwacht**	Label: ob der Kredit nicht vollständig zurückgezahlt wurde (`not.fully.paid`). Ausnahme ohne Labels: Isolation Forest zur Anomalieerkennung.
5-Support_Vector_Machines	**überwacht** meist	Label: die Iris-Art. Ausnahme ohne Labels: One-Class SVM zur Anomalieerkennung.
6-K_Means_Clustering	**unüberwacht** Clustering	Verwendet keine Labels; die Spalte `Private` dient im Kurs nur zur Bewertung. Die Cluster-Nummern werden zufällig vergeben.
7-Principal_Component_ Analysis	**unüberwacht** Dimensionsreduktion	Sucht die Richtungen der größten Streuung in den Daten, nicht Gruppen. Ein Werkzeug zur Datenaufbereitung und Visualisierung, kein Vorhersagemodell.
8-Recommender_Systems	**eigene Kategorie**	Ähnlichkeit, berechnet aus der Korrelation von Bewertungen, hat keine Zielvariable (näher am unüberwachten Lernen). Matrixfaktorisierung (SVD) lernt, bekannte Bewertungen vorherzusagen, und wird per RMSE auf zurückgehaltenen Bewertungen beurteilt — praktisch ist das überwachtes Lernen. Empfehlungen auf Basis von Produktmerkmalen (content-based) sind ebenfalls überwacht.
9-Natural_Language_ Processing	**im Kurs: überwacht**	Yelp-Projekt: Das Label ist die Zahl der Sterne (1 vs. 5), Modell `MultinomialNB`, Bewertung mit der Konfusionsmatrix. Allgemein umfasst NLP alle Arten: überwacht (Sentiment, NER), unüberwacht (Topic Modeling, Text-Clustering) und selbstüberwacht (Word2Vec, GloVe, Sprachmodelle).

Das Keras-Modul (Deep Learning, LendingClub-Projekt) ist überwachtes Lernen — Label `loan_repaid`. Der einfachste Beleg, dass Deep Learning eine Modellart ist und keine Lernart.

3. Finanz-, Börsen- und Politikprognosen: Was wählen?

Es gibt nicht den einen besten Ansatz — es hängt von den Daten und der Aufgabe ab. Die Reihenfolge der Entscheidungen ist aber einfach: (1) Wenn du etwas vorhersagen willst und ein Label hast, ist das eine Aufgabe für überwachtes Lernen; (2) erst dann wählst du das Modell und beginnst mit einem einfachen. Bei Finanzdaten gewinnen oft einfache Modelle, und neuronale Netze sind nicht automatisch besser.

3.1 Art des Lernens

ANSATZ	WOFÜR GEEIGNET	VORTEILE	NACHTEILE	WANN WÄHLEN
Überwacht supervised	Vorhersage von Kursrichtung und Rendite, Wahlergebnissen, Wirtschaftsindikatoren — überall, wo es eine Zielvariable gibt	Optimiert genau das, was du vorhersagen willst; das Ergebnis lässt sich auf Testdaten messen und mit einer Baseline vergleichen	Braucht ein gut definiertes Label und gute Merkmale; Overfitting und Datenlecks passieren leicht, besonders bei Finanzdaten	Immer, wenn das Ziel eine Vorhersage ist — das ist der Ausgangspunkt
Unüberwacht unsupervised: K-Means, PCA, Anomalieerkennung, Topic Modeling	Erkennen von Marktregimen, Gruppieren von Wählern, Märkten und Texten, Reduktion der Merkmalszahl, Anomalieerkennung	Braucht keine Labels; entdeckt die Struktur der Daten	Sagt allein nichts vorher; das Ergebnis muss interpretiert werden (Cluster-Nummern sind zufällig); die Qualität ist schwer zu beurteilen	Als Ergänzung: Merkmalsaufbereitung, Regime-Filter, Datenkontrolle

3.2 Art des Modells (bei überwachten Aufgaben)

MODELL	VORTEILE	NACHTEILE	WANN WÄHLEN
Lineare Modelle lineare und logistische Regression, Ridge, Lasso	Wenige Parameter, daher das geringste Overfitting-Risiko bei starkem Rauschen; am einfachsten zu interpretieren (Koeffizienten)	Erfassen keine Nichtlinearitäten und Interaktionen, außer du fügst sie als Merkmale hinzu	Erster Benchmark; wenige Daten, viel Rauschen
Bäume und Boosting Random Forest, XGBoost, LightGBM	Sehr stark bei Tabellendaten — bei mittleren Datensätzen (ca. 10 Tsd. Zeilen) meist besser als neuronale Netze; erfassen Nichtlinearitäten und Interaktionen	Überanpassen leicht (tiefe Bäume); die Interpretation braucht Werkzeuge (SHAP, Permutation Importance)	Tabellendaten mit vielen Merkmalen; der Schritt nach dem linearen Modell
Neuronale Netze MLP, LSTM, Transformer, NLP-Modelle	Können komplexe zeitliche und Textmuster erfassen; am besten für Textanalyse (News, Reden)	Brauchen viele Daten, sehr anfällig für Overfitting, Blackbox, teuer im Training	Viele Daten (z. B. Tausende Instrumente, lange Historie) oder Text; wenn einfachere Modelle ihre Grenze erreicht haben

4. Was funktioniert in der Praxis?

Börse und Finanzen

- Bei Tabellendaten (technische und fundamentale Merkmale) schneiden baumbasierte Modelle gut ab, besonders Gradient Boosting. Erster Vergleichspunkt sollten aber ein lineares Modell und eine einfache Baseline sein.
- Neuronale Netze (LSTM, Transformer) verlieren bei einem einzelnen Instrument und begrenzter Historie oft gegen einfachere Modelle, weil Finanzdaten verrauscht und nicht stationär sind. In Benchmarks zur Zeitreihenprognose schlug ein einfaches lineares Modell komplexe Transformer auf allen neun Datensätzen (Zeng et al., 2023).
- Bei großen Datensätzen kann das Ergebnis anders ausfallen: In einer Studie zu US-Aktien (Tausende Aktien, mehrere Jahrzehnte) schlugen Bäume und neuronale Netze die linearen Modelle. Flache Netze genügten jedoch — das beste hatte 3 verdeckte Schichten —, und das monatliche R^2 lag bei nur 0,33–0,40 % (Gu, Kelly, Xiu, 2020).
- Unüberwachtes Lernen hilft beim Erkennen von Regimen (z. B. Trend- vs. Seitwärtsmarkt) — vorausgesetzt, du passt das Regime-Modell ausschließlich auf Vergangenheitsdaten an.
- Realistische Erwartungen: Die Vorhersagbarkeit der Märkte ist gering, und der Vorteil nach Transaktionskosten noch geringer.

Politische Prognosen

- Es gibt wenige Wahlen, also auch wenige Labels. Professionelle Prognosen beruhen vor allem auf der statistischen Kombination vieler Umfragen und „fundamentaler" Daten (Wirtschaft, frühere Ergebnisse), nicht auf großen ML-Modellen.
- Überwachtes Lernen ist dort sinnvoll, wo es viele Beobachtungen gibt: auf Ebene von Wahlkreisen oder Regionen, aus Umfragedaten, demografischen Daten und historischen Ergebnissen.
- NLP (Sentiment aus sozialen Medien, Reden, News) kann ein zusätzliches Merkmal sein, hat als alleinige Methode zur Wahlvorhersage aber eine schwache Bilanz — eine Übersichtsarbeit nannte die Vorhersagekraft von Twitter „stark übertrieben" (Gayo-Avello, 2012).
- Unüberwachtes Lernen: Themen gruppieren, Wähler segmentieren.

Allgemeine Regeln

- Hast du ein Label (Wahlergebnis, Kursrichtung, steigt/fällt)? → überwachtes Lernen. Mit einem einfachen Modell und dem Vergleich mit einer Baseline beginnen.
- Willst du die Struktur von Daten ohne Labels verstehen? → unüberwachtes Lernen.
- Neuronale Netze erst testen, wenn viele Daten vorliegen und einfachere Modelle ihre Grenze erreicht haben.

5. Bevor du einem Ergebnis vertraust

Dieses Kapitel fehlte im Original. Bei Finanzprognosen entscheidet häufiger die Art, wie das Modell geprüft wird, über das Ergebnis als der Algorithmus selbst.

- **Validierung ohne Datenleck.** Daten chronologisch teilen und per Walk-Forward testen. Zum Tuning der Parameter Kreuzvalidierung mit Bereinigung (Purged k-Fold) und einer Pause (Embargo) zwischen den Mengen verwenden (López de Prado, 2018). Alles, was sich an die Daten anpasst — Skalierung, PCA, Regime-Modell —, nur auf der Vergangenheit anpassen.
- **Baseline.** Mit der einfachsten Antwort vergleichen: „steigt immer" oder „immer die häufigste Klasse". Der S&P 500 stieg 1951–2025 an 53,7 % der Handelstage — eine Trefferquote von 55 % bei der Richtung ist also kaum

mehr als diese einfache Regel.

- **Definition des Labels.** Horizont, Bewegungsschwelle und das, was als Erfolg zählt, festlegen — z. B. die Triple-Barrier-Methode: Take Profit, Stop Loss und Zeitlimit (López de Prado, 2018).
- **Kosten.** Ziel ist das Ergebnis nach Gebühren und Slippage, nicht die Trefferquote.
- **Backtest-Overfitting.** Je mehr Varianten du testest, desto leichter entsteht ein zufällig gutes Ergebnis. Es helfen die Deflated Sharpe Ratio (Bailey, López de Prado, 2014), Permutationstests und eine Sensitivitätsanalyse der Parameter.
- **Bei unausgewogenen Klassen reicht die Accuracy nicht.** Auf die Konfusionsmatrix sowie Recall und Precision der kleineren Klasse schauen. Beispiel aus dem Kurs: Der Random Forest hatte 84,55 % Accuracy bei einer Baseline von 84,59 % und erkannte 2 % der nicht zurückgezahlten Kredite.

6. Einsatz in einer regelbasierten Strategie (z. B. Donchian-Breakouts)

- **Meta-Labeling.** Die Regel erzeugt ein Signal, und ein überwachtes Modell beurteilt, ob es genommen wird und wie groß die Position sein soll. Label: ob der jeweilige Trade profitabel war. Das ist meist realistischer, als den Preis selbst vorherzusagen (López de Prado, 2018).
- **Regime-Filter.** Ein unüberwachtes Modell (HMM, Gaußsche Mischverteilung, K-Means) kann einen regelbasierten Seitwärtsmarkt-Filter ersetzen. Es mit einem rollierenden Fenster nur auf Vergangenheitsdaten anpassen und die Zustände oder Cluster selbst interpretieren — ihre Nummern sind zufällig.

7. Realistisches Fazit

AUFGABE	FÜR DEN START	WORAUF ACHTEN
Börsenprognose / Trading	Überwacht: lineares Modell als Benchmark, dann Boosting (XGBoost, LightGBM)	Walk-Forward, Baseline, Kosten; bei regelbasierter Strategie — Meta-Labeling
Finanzprognosen (Makro, Indikatoren)	Überwacht: statistische oder lineare Modelle, dann Bäume	Monats- oder Quartalsdaten sind wenige Beobachtungen — einfache Modelle
Politische Prognosen	Statistische Kombination von Umfragen + überwachte Modelle auf Regionalebene; NLP als zusätzliches Merkmal	Wenige Wahlen = wenige Labels
Erkennung von Regimen / Anomalien	Unüberwacht: HMM, Gaußsche Mischverteilungen, K-Means, Isolation Forest	Nur auf Vergangenheitsdaten; Zustände müssen interpretiert werden
Analyse großer Textmengen (News, Social Media)	Neuronale Netze / NLP-Modelle (z. B. Transformer-Modelle für Sentiment)	Das Ergebnis (Sentiment) ist meist ein Merkmal für ein weiteres überwachtes Modell

FAZIT

Für die meisten Finanz- und Politikprognosen ist überwachtes Lernen der Ausgangspunkt — beginnend mit einem einfachen Modell und dem Vergleich mit einer Baseline. Neuronale Netze sind nicht per Definition „besser“: Bei wenigen verrauschten Daten schneiden sie oft schlechter oder nur geringfügig besser ab, bei höherem Overfitting-Risiko und höheren Kosten; im Vorteil sind sie bei großen Datensätzen und bei Text. Unüberwachtes Lernen als Hilfswerkzeug betrachten (Regime, Merkmale, Anomalien), nicht als zentralen Vorhersagemotor. Unabhängig vom Modell entscheidet eine saubere Validierung über das Ergebnis: ohne Datenleck, mit Baseline und mit Kosten.

A. Was ich gegenüber dem Original korrigiert habe

Einteilung der Kursthemen (Screenshot)

1. NLP: Im Kurs ist das überwachtes Lernen (Yelp-Projekt mit der Sternezahl als Label), nicht „teilweise unüberwacht".
2. Empfehlungssysteme: statt „die grundlegenden Ansätze sind unsupervised" — eine eigene Kategorie; die Matrixfaktorisierung sagt bekannte Bewertungen vorher, ist also praktisch überwacht.
3. PCA: sucht die Richtungen der größten Streuung, nicht Gruppen; ein Werkzeug zur Datenaufbereitung.
4. Ergänzt: KNN ist nicht K-Means; Ausnahmen ohne Labels (One-Class SVM, Isolation Forest); das Keras-Modul als Beispiel, dass Deep Learning überwacht sein kann.

Text zu Prognosen (ML_Trading.pdf)

5. Art des Lernens von der Art des Modells getrennt — Deep Learning ist eine Modellfamilie, keine Alternative zu supervised (Kapitel 1 und Tabelle 3.2).
6. Die Behauptung gestrichen, supervised neige „weniger zu Overfitting". Overfitting hängt von der Komplexität des Modells und der Datenmenge ab — im Kurs hatte ein unbeschränkter Entscheidungsbaum 73 % Accuracy bei einer Baseline von 84,6 %.
7. Interpretation: einfach bei linearen Modellen, aber nicht bei Random Forests und Boosting.
8. Präzisiert, wann neuronale Netze verlieren (wenige Daten, ein Instrument) und wann sie gewinnen (große Datensätze, Text) — mit Studienergebnissen.
9. Politische Prognosen: wenige Labels, die Rolle der Umfragekombination, der schwache Vorhersagewert von Social-Media-Sentiment.
10. Kapitel 5 und 6 ergänzt: Validierung ohne Datenleck, Baseline, Definition des Labels, Kosten, Backtest-Overfitting; Meta-Labeling und Regime-Filter.

B. Quellen

- Gu, S., Kelly, B., Xiu, D. (2020). *Empirical Asset Pricing via Machine Learning.* Review of Financial Studies; NBER Working Paper w25398. nber.org/papers/w25398.pdf
- Zeng, A., Chen, M., Zhang, L., Xu, Q. (2023). *Are Transformers Effective for Time Series Forecasting?* AAAI. arxiv.org/abs/2205.13504
- Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). *Why do tree-based models still outperform deep learning on typical tabular data?* NeurIPS. arxiv.org/abs/2207.08815
- Gayo-Avello, D. (2012). *„I Wanted to Predict Elections with Twitter and all I got was this Lousy Paper" — A Balanced Survey on Election Prediction using Twitter Data.* arxiv.org/abs/1204.6441
- Crestmont Research. *Stock Yo-Yo* — S&P 500: 53,7 % Aufwärtstage 1951–2025. crestmontresearch.com/docs/Stock-Yo-Yo.pdf
- López de Prado, M. (2018). *Advances in Financial Machine Learning.* Wiley — Purged-k-Fold-Validierung mit Embargo, Triple-Barrier-Methode, Meta-Labeling.
- Bailey, D. H., López de Prado, M. (2014). *The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality.* Journal of Portfolio Management.
- Ergebnisse aus dem Kurs (Random Forest, Entscheidungsbaum, Yelp- und Keras-Projekt) — aus deinen Notebooks, ausführlich beschrieben im PDF „ML-Ergebnisse richtig lesen".