WERSJA POPRAWIONA · 16.10.2026

Machine Learning w predykcjach finansowych, giełdowych i politycznych

Który rodzaj uczenia i jaki model wybrać — poprawiona wersja Twoich dwóch tekstów: podziału tematów kursu na uczenie nadzorowane i nienadzorowane oraz notatki „ML_Trading".

CZĘŚCI 1–2
Pojęcia i tematy kursu: co jest nadzorowane, co nienadzorowane, gdzie jest deep learning.

CZĘŚCI 3–7
Poprawiony tekst o predykcjach, z dwoma nowymi rozdziałami (5 i 6), których brakowało w oryginale.

NA KOŃCU
Lista zmian względem oryginału i źródła, na których opierają się poprawki.

1. Najpierw pojęcia: rodzaj uczenia to nie to samo co rodzaj modelu

Uczenie nadzorowane (supervised) — dane mają etykietę, czyli zmienną docelową, a model uczy się ją przewidywać. Gdy etykieta jest liczbą, to regresja (np. zwrot, wydatki); gdy jest klasą — klasyfikacja (np. wzrost/spadek, kliknie/nie kliknie).

Uczenie nienadzorowane (unsupervised) — etykiety nie ma. Algorytm szuka struktury w samych danych: grup (klastrowanie), kierunków największej zmienności (PCA) albo nietypowych obserwacji (anomalie).

Uczenie samonadzorowane (self-supervised) — etykietę tworzy się z samych danych, np. następne słowo w tekście. Tak uczą się Word2Vec i modele językowe; zwykle zalicza się je do metod bez ręcznych etykiet.

Deep learning to nie kolejny rodzaj uczenia, tylko rodzina modeli — sieci neuronowe. Sieć może uczyć się nadzorowanie (LSTM przewidujący zwrot), nienadzorowanie (autoenkoder) albo samonadzorowanie (model językowy).

Rodzina modeli × rodzaj uczenia — przykłady

RODZINA MODELI	UCZENIE NADZOROWANE — JEST ETYKIETA	BEZ ETYKIETY — NIENADZOROWANE / SAMONADZOROWANE
Modele liniowe i statystyczne	regresja liniowa, regresja logistyczna, Ridge, Lasso	PCA
Metody geometryczne (odległość, margines)	KNN, SVM	K-Means, One-Class SVM
Drzewa i ich zespoły	drzewo decyzyjne, Random Forest, XGBoost, LightGBM	Isolation Forest (anomalie)
Sieci neuronowe (deep learning)	MLP, LSTM i Transformer do prognoz, klasyfikacja sentymentu	autoenkodery; Word2Vec i modele językowe (samonadzorowane)

NAJWAŻNIEJSZA POPRAWKA
W oryginalnym tekście deep learning stał obok supervised i unsupervised jak trzecia możliwość. To błąd pojęciowy: LSTM czy Transformer, który przewiduje cenę, uczy się nadzorowanie — tak samo jak XGBoost. Właściwe porównanie to **proste modele (liniowe, drzewa) kontra sieci neuronowe**, wszystkie w ramach uczenia nadzorowanego.

2. Tematy kursu: nadzorowane czy nienadzorowane?

Poprawiony podział tematów z Twojej listy. Tam, gdzie znam Twój notebook z kursu, podaję etykietę, której używa.

TEMAT	RODZAJ UCZENIA	DLACZEGO / NA CO UWAŻAĆ
1-Linear_Regression	**nadzorowane** regresja	Etykieta to liczba — w projekcie roczne wydatki klienta (`Yearly Amount Spent`).
2-Logistic_Regression	**nadzorowane** klasyfikacja	Etykieta to klasa — kliknięcie w reklamę (`Clicked on Ad`).
3-K_Nearest_Neighbors	**nadzorowane** klasyfikacja (zwykle)	Potrzebuje etykiet (`TARGET CLASS`). Nie mylić z K-Means. Bez etykiet działa tylko samo wyszukiwanie najbliższych sąsiadów (`NearestNeighbors`).
4-Decision_Trees_und_ Random_Forests	**nadzorowane**	Etykieta: czy kredyt nie został w pełni spłacony (`not.fully.paid`). Wyjątek bez etykiet: Isolation Forest do wykrywania anomalii.
5-Support_Vector_Machines	**nadzorowane** zwykle	Etykieta: gatunek irysa. Wyjątek bez etykiet: One-Class SVM do wykrywania anomalii.
6-K_Means_Clustering	**nienadzorowane** klastrowanie	Nie używa etykiet; kolumna `Private` służy w kursie tylko do oceny. Numery klastrów są nadawane losowo.
7-Principal_Component_ Analysis	**nienadzorowane** redukcja wymiarów	Szuka kierunków największej zmienności danych, a nie grup. To narzędzie do przygotowania danych i wizualizacji, nie model predykcyjny.
8-Recommender_Systems	**osobna kategoria**	Podobieństwo liczone z korelacji ocen nie ma zmiennej docelowej (bliżej nienadzorowanego). Faktoryzacja macierzy (SVD) uczy się przewidywać znane oceny i ocenia się ją przez RMSE na odłożonych ocenach — w praktyce to uczenie nadzorowane. Rekomendacje na podstawie cech produktu (content-based) też są nadzorowane.
9-Natural_Language_ Processing	**w kursie: nadzorowane**	Projekt Yelp: etykieta to liczba gwiazdek (1 vs 5), model `MultinomialNB` , ocena macierzą pomyłek. Ogólnie NLP obejmuje wszystkie rodzaje: nadzorowane (sentyment, NER), nienadzorowane (topic modeling, klastrowanie tekstów) i samonadzorowane (Word2Vec, GloVe, modele językowe).

Moduł Keras (deep learning, projekt LendingClub) to uczenie nadzorowane — etykieta `loan_repaid` . To najprostszy dowód, że deep learning jest rodzajem modelu, a nie rodzajem uczenia.

3. Predykcje finansowe, giełdowe i polityczne: co wybrać?

Nie ma jednego najlepszego podejścia — zależy od danych i zadania. Kolejność decyzji jest jednak prosta: (1) jeśli chcesz coś przewidzieć i masz etykietę, to zadanie dla uczenia nadzorowanego; (2) dopiero potem wybierasz model, zaczynając od prostego. Na danych finansowych proste modele często wygrywają, a sieci neuronowe nie są automatycznie lepsze.

3.1 Rodzaj uczenia

PODEJŚCIE	DO CZEGO SIĘ NADAJE	ZALETY	WADY	KIEDY WYBIERAĆ
Nadzorowane supervised	Przewidywanie kierunku ceny i zwrotu, wyników wyborów, wskaźników ekonomicznych — wszędzie, gdzie istnieje zmienna docelowa	Optymalizuje dokładnie to, co chcesz przewidzieć; wynik da się zmierzyć na danych testowych i porównać z baseline	Wymaga dobrze zdefiniowanej etykiety i dobrych cech; łatwo o przeuczenie i przeciek danych, szczególnie na danych finansowych	Zawsze, gdy celem jest predykcja — to punkt wyjścia
Nienadzorowane unsupervised: K-Means, PCA, wykrywanie anomalii, topic modeling	Wykrywanie reżimów rynkowych, grupowanie wyborców, rynków i tekstów, redukcja liczby cech, wykrywanie anomalii	Nie potrzebuje etykiet; odkrywa strukturę danych	Samo niczego nie prognozuje; wynik trzeba zinterpretować (numery klastrów są losowe); trudno ocenić jakość	Jako uzupełnienie: przygotowanie cech, filtr reżimu, kontrola danych

3.2 Rodzaj modelu (w zadaniach nadzorowanych)

MODEL	ZALETY	WADY	KIEDY WYBIERAĆ
Modele liniowe regresja liniowa i logistyczna, Ridge, Lasso	Mało parametrów, więc najmniejsze ryzyko przeuczenia przy silnym szumie; najłatwiejsza interpretacja (współczynniki)	Nie łapią nieliniowości i interakcji, chyba że dodasz je jako cechy	Pierwszy benchmark; mało danych, dużo szumu
Drzewa i boosting Random Forest, XGBoost, LightGBM	Bardzo mocne na danych tabelarycznych — przy średnich zbiorach (ok. 10 tys. wierszy) zwykle lepsze od sieci neuronowych; łapią nieliniowości i interakcje	Łatwo się przeuczają (głębokie drzewa); interpretacja wymaga narzędzi (SHAP, permutation importance)	Dane tabelaryczne z wieloma cechami; krok po modelu liniowym
Sieci neuronowe MLP, LSTM, Transformer, modele NLP	Mogą łapać złożone wzorce czasowe i tekstowe; najlepsze do analizy tekstu (newsy, przemówienia)	Potrzebują dużo danych, bardzo podatne na przeuczenie, czarna skrzynka, drogie w treningu	Dużo danych (np. tysiące instrumentów, długa historia) albo tekst; gdy prostsze modele osiągnęły limit

4. Co sprawdza się w praktyce?

Giełda i finanse

- Na danych tabelarycznych (cechy techniczne i fundamentalne) dobrze wypadają modele drzewiaste, zwłaszcza gradient boosting. Pierwszym punktem odniesienia powinien jednak być model liniowy i prosty baseline.
- Sieci neuronowe (LSTM, Transformer) przy pojedynczym instrumencie i ograniczonej historii często przegrywają z prostszymi modelami, bo dane finansowe są zaszumione i niestacjonarne. W benchmarkach prognozowania szeregów czasowych prosty model liniowy pokonał złożone Transformery na wszystkich dziewięciu zbiorach danych (Zeng i in., 2023).
- Przy dużych zbiorach wynik bywa inny: w badaniu na amerykańskich spółkach (tysiące akcji, kilkadziesiąt lat) drzewa i sieci neuronowe pokonały modele liniowe. Wystarczyły jednak płytkie sieci — najlepsza miała 3 warstwy ukryte — a miesięczne R^2 wyniosło zaledwie 0,33–0,40% (Gu, Kelly, Xiu, 2020).
- Uczenie nienadzorowane przydaje się do wykrywania reżimów (np. rynek trendowy vs boczny) — pod warunkiem, że model reżimów dopasowujesz wyłącznie na danych z przeszłości.
- Realistyczne oczekiwania: przewidywalność rynków jest mała, a przewaga po kosztach transakcyjnych jeszcze mniejsza.

Predykcje polityczne

- Wyborów jest niewiele, więc i etykiet jest mało. Profesjonalne prognozy opierają się głównie na statystycznym łączeniu wielu sondaży i danych „fundamentalnych" (gospodarka, wcześniejsze wyniki), a nie na dużych modelach ML.
- Uczenie nadzorowane ma sens tam, gdzie obserwacji jest dużo: na poziomie okręgów lub regionów, z danych sondażowych, demograficznych i historycznych wyników.
- NLP (sentyment z mediów społecznościowych, przemówień, newsów) może być dodatkową cechą, ale jako samodzielny sposób przewidywania wyborów ma słabą historię — przegląd badań uznał moc predykcyjną Twittera za „mocno przesadzoną" (Gayo-Avello, 2012).
- Uczenie nienadzorowane: grupowanie tematów, segmentacja wyborców.

Ogólne zasady

- Masz etykietę (wynik wyborów, kierunek ceny, wzrost/spadek)? → uczenie nadzorowane. Zacznij od prostego modelu i porównania z baseline.
- Chcesz zrozumieć strukturę danych bez etykiet? → uczenie nienadzorowane.
- Sieci neuronowe testuj dopiero wtedy, gdy masz dużo danych, a prostsze modele osiągnęły limit.

5. Zanim zaufasz wynikowi

Tego rozdziału brakowało w oryginale. W predykcjach finansowych o wyniku częściej decyduje sposób sprawdzania modelu niż sam algorytm.

- **Walidacja bez przecieku danych.** Dane dziel chronologicznie i testuj metodą walk-forward. Do strojenia parametrów używaj walidacji krzyżowej z oczyszczaniem (purged k-fold) i przerwą (embargo) między zbiorami (López de Prado, 2018). Wszystko, co dopasowuje się do danych — skalowanie, PCA, model reżimów — dopasowuj tylko na przeszłości.
- **Baseline.** Porównuj z najprostszą odpowiedzią: „zawsze wzrost" albo „zawsze klasa większościowa". S&P 500 rósł w 53,7% dni sesyjnych w latach 1951–2025, więc 55% trafności kierunku to niewiele więcej niż ta prosta reguła.
- **Definicja etykiety.** Ustal horyzont, próg ruchu i to, co liczy się jako sukces — np. metoda potrójnej bariery: take profit, stop loss i limit czasu (López de Prado, 2018).
- **Koszty.** Celem jest wynik po opłatach i poślizgu cenowym, a nie trafność.
- **Przeuczenie backtestu.** Im więcej wariantów przetestujesz, tym łatwiej o przypadkowo dobry wynik. Pomagają Deflated Sharpe Ratio (Bailey, López de Prado, 2014), testy permutacyjne i analiza wrażliwości parametrów.
- **Przy niezbalansowanych klasach trafność to za mało.** Patrz na macierz pomyłek oraz recall i precision mniejszej klasy. Przykład z kursu: las losowy miał 84,55% trafności przy baseline 84,59% i wykrywał 2% niespłaconych kredytów.

6. Zastosowanie w strategii opartej na regułach (np. wybicia Donchiana)

- **Meta-labeling.** Reguła generuje sygnał, a model nadzorowany ocenia, czy go wziąć i jak dużą pozycję otworzyć. Etykieta: czy dana transakcja była zyskowna. To zwykle bardziej realne niż przewidywanie samej ceny (López de Prado, 2018).
- **Filtr reżimu.** Model nienadzorowany (HMM, mieszanina rozkładów Gaussa, K-Means) może zastąpić regułowy filtr rynku bocznego. Dopasowuj go kroczącym oknem tylko na przeszłych danych, a stany lub klastry interpretuj samodzielnie — ich numery są losowe.

7. Realistyczne podsumowanie

ZADANIE	NA START	NA CO UWAŻAĆ
Predykcja giełdowa / trading	Nadzorowane: model liniowy jako benchmark, potem boosting (XGBoost, LightGBM)	Walk-forward, baseline, koszty; przy strategii regułowej — meta-labeling
Predykcje finansowe (makro, wskaźniki)	Nadzorowane: modele statystyczne lub liniowe, potem drzewa	Dane miesięczne lub kwartalne to mało obserwacji — proste modele
Predykcje polityczne	Statystyczne łączenie sondaży + modele nadzorowane na poziomie regionów; NLP jako dodatkowa cecha	Mało wyborów = mało etykiet
Wykrywanie reżimów / anomalii	Nienadzorowane: HMM, mieszaniny Gaussa, K-Means, Isolation Forest	Tylko na danych z przeszłości; stany trzeba zinterpretować
Analiza dużych ilości tekstu (newsy, social media)	Sieci neuronowe / modele NLP (np. modele transformerowe do sentymentu)	Wynik (sentyment) to zwykle cecha dla kolejnego modelu nadzorowanego

WNIOSEK

Do większości predykcji finansowych i politycznych punktem wyjścia jest uczenie nadzorowane — zaczynając od prostego modelu i porównania z baseline. Sieci neuronowe nie są „lepsze" z definicji: przy małej ilości zaszumionych danych często wypadają gorzej albo tylko nieznacznie lepiej, przy większym ryzyku przeuczenia i koszcie; przewagę mają przy dużych zbiorach i przy tekście. Uczenie nienadzorowane traktuj jako narzędzie pomocnicze (reżimy, cechy, anomalie), a nie główny silnik predykcji. Niezależnie od modelu o wyniku decyduje rzetelna walidacja: bez przecieku danych, z baseline i z kosztami.

A. Co poprawiłem względem oryginału

Podział tematów kursu (zrzut ekranu)

1. NLP: w kursie to uczenie nadzorowane (projekt Yelp z etykietą liczby gwiazdek), a nie „częściowo nienadzorowane".
2. Systemy rekomendacyjne: zamiast „podstawowe podejścia są unsupervised" — osobna kategoria; faktoryzacja macierzy przewiduje znane oceny, więc w praktyce jest nadzorowana.
3. PCA: szuka kierunków największej zmienności, a nie grup; to narzędzie do przygotowania danych.
4. Dodane: KNN to nie K-Means; wyjątki bez etykiet (One-Class SVM, Isolation Forest); moduł Keras jako przykład, że deep learning bywa nadzorowany.

Tekst o predykcjach (ML_Trading.pdf)

5. Rozdzielony rodzaj uczenia od rodzaju modelu — deep learning to rodzina modeli, a nie alternatywa dla supervised (rozdział 1 i tabela 3.2).
6. Usunięte twierdzenie, że supervised ma „mniejszą skłonność do overfittingu". Przeuczenie zależy od złożoności modelu i ilości danych — w kursie drzewo decyzyjne bez ograniczeń miało 73% trafności przy baseline 84,6%.
7. Interpretacja: łatwa dla modeli liniowych, ale nie dla lasów losowych i boostingu.
8. Doprecyzowane, kiedy sieci neuronowe przegrywają (mało danych, jeden instrument), a kiedy wygrywają (duże zbiory, tekst) — z wynikami badań.
9. Prognozy polityczne: mało etykiet, rola łączenia sondaży, słaba wartość predykcyjna sentymentu z mediów społecznościowych.
10. Dodane rozdziały 5 i 6: walidacja bez przecieku, baseline, definicja etykiety, koszty, przeuczenie backtestu; meta-labeling i filtr reżimu.

B. Źródła

- Gu, S., Kelly, B., Xiu, D. (2020). *Empirical Asset Pricing via Machine Learning.* Review of Financial Studies; NBER Working Paper w25398. nber.org/papers/w25398.pdf
- Zeng, A., Chen, M., Zhang, L., Xu, Q. (2023). *Are Transformers Effective for Time Series Forecasting?* AAAI. arxiv.org/abs/2205.13504
- Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). *Why do tree-based models still outperform deep learning on typical tabular data?* NeurIPS. arxiv.org/abs/2207.08815
- Gayo-Avello, D. (2012). *„I Wanted to Predict Elections with Twitter and all I got was this Lousy Paper" — A Balanced Survey on Election Prediction using Twitter Data.* arxiv.org/abs/1204.6441
- Crestmont Research. *Stock Yo-Yo* — S&P 500: 53,7% dni wzrostowych w latach 1951–2025. crestmontresearch.com/docs/Stock-Yo-Yo.pdf
- López de Prado, M. (2018). *Advances in Financial Machine Learning.* Wiley — walidacja purged k-fold z embargo, metoda potrójnej bariery, meta-labeling.
- Bailey, D. H., López de Prado, M. (2014). *The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality.* Journal of Portfolio Management.
- Wyniki z kursu (las losowy, drzewo decyzyjne, projekty Yelp i Keras) — z Twoich notebooków, opisane szczegółowo w PDF „Interpretacja 8 notebooków ML".